

考研数学基础讲义

概率论与数理统计 知识背诵版

本版本由葛红儒根据考研大纲及浙大版教材整理所得

里面如有问题，欢迎批评指正

目录

一、随机事件和概率.....	3
1.1 样本空间、随机事件.....	3
1.2 概率、条件概率.....	5
1.3 事件独立性.....	10
二、随机变量及其分布.....	13
2.1 随机变量及其分布函数.....	13
2.2 离散型随机变量及其概率分布.....	14
2.3 连续型随机变量及其概率密度.....	18
2.4 随机变量函数的分布.....	22
三、多维随机变量及其分布.....	23
3.1 多维随机变量及分布.....	23
3.2 随机变量的独立性及不相关性.....	29
3.3 二维均匀分布和二维正态分布.....	30
3.4 两个随机变量的函数的分布.....	32
四、随机变量的数字特征.....	35
4.1 随机变量数字特征.....	35
4.2 随机变量函数的数学期望.....	40
五、大数定律和中心极限定理.....	42
5.1 切比雪夫不等式.....	42
5.2 大数定律.....	42
5.3 中心极限定理.....	44
六、数理统计的基本概念.....	46
6.1 随机样本与统计量.....	46
6.2 常用抽样分布.....	48
6.3 正态总体的常用抽样分布.....	52
6.4 经验分布函数(数三).....	53
七、参数估计.....	55
7.1 参数的点估计、估计量与估计值.....	55
7.2 矩估计法和最大似然估计法.....	55
7.3 估计量的评选标准(数一).....	59
7.4 区间估计(数一).....	61
八、假设检验(数一).....	65
8.1 假设检验的概念.....	65
8.2 正态总体的假设检验.....	67

一、随机事件和概率

1.1 样本空间、随机事件

大纲要求

了解样本空间(基本事件空间)的概念,

理解随机事件的概念,

掌握事件的关系及运算

随机现象

在个别试验中其结果呈现出不确定性,但在大量重复试验中其结果又具有统计规律性的现象,我们称之为**随机现象**。

随机试验

对某一事物的某一特征的观察,统称试验。

具有以下特点的试验:

- 1, 可以在相同的条件下重复地进行
- 2, 每次试验的可能结果不止一个,并且能事先明确试验的所有可能结果
- 3, 进行一次试验之前不能确定哪一个结果会出现

称为随机试验。通常用 E 表示。

样本空间

随机试验 E 的所有可能结果组成的集合称为样本空间,记为 S 。样本空间的元素,即 E 的每个结果,称为样本点(或基本事件)。

试验 E 的样本空间 S 的子集, 称为 E 的**随机事件**, 简称事件。由一个样本点组成的单点集, 称为**基本事件**

在每次试验中, 当且仅当这一子集中的一个样本点出现时, 称这一**事件发生**。

样本空间 S 包含所有的样本点, 它是 S 自身的子集, 在每次试验中它总是发生的, S 称为**必然事件**。空集 $\emptyset$ 不包含任何样本点, 它也作为样本空间的子集, 它在每次试验中都不发生, 它称为**不可能事件**。

事件的关系及运算

事件是一个集合, 因而事件间的关系及运算, 自然按照集合论中集合之间的关系和集合运算来处理。

1, $A \subset B$, 称事件 B 包含事件 A , 当事件 A 发生时必导致事件 B 发生。

2, $A = B$, 事件 A 与事件 B 相等。

3, $A \cup B$, 事件 A 与事件 B 的和事件。当且仅当 A, B 中至少有一个发生时, 事件 $A \cup B$ 发生。

4, $A \cap B$, 事件 A 与事件 B 的积事件。当且仅当 A, B 同时发生时, 事件 $A \cap B$ 发生。 $A \cap B$ 也记作 AB

5, $A - B$, 事件 A 与事件 B 的差事件。当且仅当 A 发生 B 不发生时, 事件 $A - B$ 发生。

6, 若 $A \cap B = \emptyset$, 称事件 A 与事件 B 是互不相容的, 或互斥的。这指的是事件 A 与事件 B 不能同时发生。基本事件是两两互不相容的。

7, 若 $A \cup B = S$ 且 $A \cap B = \emptyset$, 则称事件 A 与事件 B 互为逆事件, (或对立事件)。

对于每次试验而言, 事件 A, B 中必有一个发生, 且仅有一个发生。 A 的对立事件记为 $\bar{A}$, $\bar{A} = S - A$

运算律

交换律: $A \cup B = B \cup A$, $A \cap B = B \cap A$

结合律: $A \cup (B \cup C) = (A \cup B) \cup C$; $A \cap (B \cap C) = (A \cap B) \cap C$

分配律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$; $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$

德摩根律: $\overline{A \cup B} = \bar{A} \cap \bar{B}$; $\overline{A \cap B} = \bar{A} \cup \bar{B}$

差化积: $A - B = A\bar{B} = A - (AB)$

运算顺序: 逆交并差, 括号优先

1.2 概率、条件概率

大纲要求

理解概率、条件概率的概念,

掌握概率的基本性质,

会计算古典型概率和几何型概率,

掌握概率的加法公式、减法公式、乘法公式、全概率公式以及贝叶斯 (Bayes) 公式。

概率、条件概率的概念

频率

在相同的条件下，进行了 n 次试验，在这 n 次试验中，事件 A 发生的次数 n_A ，称为事件 A 发生的**频数**。比值 n_A/n 称为事件 A 发生的**频率**。并记成 $f_n(A)$ 。

频率具有下述基本性质：

1，非负性 $0 \leq f_n(A) \leq 1$

2，规范性 $f_n(S) = 1$

3，可加性 若 $A_1, A_2, \dots, A_k$ 是两两互不相容的事件，则

$$f_n(A_1 \cup A_2 \cup \dots \cup A_k) = f_n(A_1) + f_n(A_2) + \dots + f_n(A_k)$$

4，稳定性，当重复试验的次数 n 逐渐增大时，频率 $f_n(A)$ 呈现出稳定性，逐渐稳定于某个常数。这个也就是通常所说的统计规律性。

概率的定义

设 E 是随机试验， S 是它的样本空间，对于 E 的每一事件 A 赋予一个实数，记为 $P(A)$ ，称为事件 A 的**概率**，如果集合函数 $P(\cdot)$ 满足下列条件：

1，非负性，对于每一个事件 A ，有 $P(A) \geq 0$

2，规范性，对于必然事件 S ，有 $P(S) = 1$

3，可列可加性，设 $A_1, A_2, \dots$ 是两两互不相容的事件，即对于 $A_i A_j = \emptyset$ ， $i \neq j$ ， $i, j = 1, 2, \dots$ ，有 $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$

当 $n \rightarrow \infty$ 时，频率 $f_n(A)$ 在一定意义下接近于概率 $P(A)$ 。

条件概率

设 A, B 是两个事件, 且 $P(A) > 0$, 称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 A 发生的**条件概率**。

条件概率 $P(\cdot | A)$ 符合概率定义中的三个条件:

- 1, 非负性, 对于每一个事件 B , 有 $P(B|A) \geq 0$
- 2, 规范性, 对于必然事件 S , 有 $P(S|A) = 1$
- 3, 可列可加性, 设 $B_1, B_2, \dots$ 是两两互不相容的事件, 有

$$P\left(\bigcup_{i=1}^{\infty} B_i | A\right) = \sum_{i=1}^{\infty} P(A_i)$$

概率的性质

- 1, $P(\emptyset) = 0$
- 2, 有限可加性 若 $A_1, A_2, \dots, A_k$ 是两两互不相容的事件, 则有

$$P(A_1 \cup A_2 \cup \dots \cup A_k) = P(A_1) + P(A_2) + \dots + P(A_k)$$

- 3, 设是 A, B 两个事件, 若 $A \subset B$, 则有

$$\begin{aligned} P(B - A) &= P(B) - P(A) \\ P(B) &\geq P(A) \end{aligned}$$

- 4, 对于任一事件 A , $P(A) \leq 1$
- 5, **逆事件的概率** 对于任一事件 A , 有

$$P(\bar{A}) = 1 - P(A)$$

- 6, **加法公式** 对于任意两事件 A, B , 有

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

对于任意三事件 A_1, A_2, A_3 , 有

$$\begin{aligned} P(A_1 \cup A_2 \cup A_3) &= P(A_1) + P(A_2) + P(A_3) - P(A_1A_2) - P(A_1A_3) - P(A_2A_3) \\ &\quad + P(A_1A_2A_3) \end{aligned}$$

可进一步推广到 n 个事件

$$\begin{aligned} P(A_1 \cup A_2 \cup \cdots \cup A_n) \\ = \sum_{i=1}^n P(A_i) - \sum_{0 \leq i < j \leq n} P(A_i A_j) + \sum_{0 \leq i < j < k \leq n} P(A_i A_j A_k) + \cdots \\ + (-1)^{n-1} P(A_1 A_2 \cdots A_n) \end{aligned}$$

古典型概率和几何型概率

古典型概率(等可能概型)

随机试验 E 具有下列特点：

- 1, 试验的样本空间只包含有限个元素(基本事件的个数有限)
- 2, 试验中每个基本事件发生的可能性相同

这种试验称为**等可能概型**，也称为**古典概型**。

它的计算公式

$$P(A) = \frac{k}{n}$$

其中 k 为 A 包含的基本事件数； n 为 S 中基本事件总数。

几何型概率

样本空间为有限区域 Ω , 若样本点落入 Ω 内任何区域 G 中的概率与区域 G 的测度成正比，则样本点落入 G 内的概率为

$$P(A) = \frac{G \text{ 的区域测度}}{\Omega \text{ 总测度}}$$

两大特征：无限性（基本事件个数无限）；等可能性（区域内每点被取到机会均等）

概率的五大公式

加法公式

$$P(A \cup B) = P(A) + P(B) - P(AB)$$
$$P(A_1 \cup A_2 \cup A_3) = P(A_1) + P(A_2) + P(A_3) - P(A_1A_2) - P(A_1A_3) - P(A_2A_3) + P(A_1A_2A_3)$$

减法公式

$$P(A - B) = P(A) - P(AB)$$

乘法公式

$$P(AB) = P(B|A) \cdot P(A)$$
$$P(ABC) = P(C|AB) \cdot P(B|A) \cdot P(A)$$

全概率公式

定义 设 S 是试验 E 的样本空间, 设 $B_1, B_2, \dots, B_n$ 为 E 的一组事件, 若

$$1, B_i B_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$$

$$2, B_1 \cup B_2 \cup \dots \cup B_n = S$$

则称 $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分。

设试验 E 的样本空间为 S , A 为 E 的事件, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且

$P(B_i) > 0, (i = 1, 2, \dots, n)$, 则

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

贝叶斯 (Bayes) 公式

设试验 E 的样本空间为 S , A 为 E 的事件, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且

$P(A) > 0, P(B_i) > 0, (i = 1, 2, \dots, n)$, 则

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

$$(i = 1, 2, \dots, n)$$

它的推导也比较简单:

$$P(B_i|A) = \frac{P(B_i A)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

如果这里 n 取 2，将 B_1 记为 B ， B_2 就是 $\bar{B}$

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$$

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})}$$

由以往的数据分析得到的是**先验概率**。拿到新信息后，重新算出来的修正概率叫做**后验概率**。

1.3 事件独立性

大纲要求

理解事件独立性的概念，

掌握用事件独立性进行概率计算的方法；

理解独立重复试验的概念，

掌握计算有关事件概率的方法。

事件独立性的概念

设 A, B 是两事件，如果满足等式

$$P(AB) = P(A)P(B)$$

则称事件 A, B **相互独立**，简称 A, B 独立。

若 $P(A) > 0$ ， $P(B) > 0$ ，则 A, B 相互独立与 A, B 互不相容不能同时成立。

若事件 A, B 相互独立，则下列各对事件也相互独立：

$$A \text{ 与 } \bar{B}, \bar{A} \text{ 与 } B, \bar{A} \text{ 与 } \bar{B},$$

两事件相互独立的含义是它们中一个已发生，不影响另一个发生的概率。如果两个事件之间没有关联或者关联很弱，那么就认为它们是相互独立的。

设 A, B, C 是三事件，如果满足等式

$$\begin{aligned} P(AB) &= P(A)P(B) \\ P(BC) &= P(B)P(C) \\ P(AC) &= P(A)P(C) \\ P(ABC) &= P(A)P(B)P(C) \end{aligned}$$

则称事件 A, B, C 相互独立

一般的，设 $A_1, A_2, \dots, A_n$ 是 n 个事件，如果对于其中任意两个，任意三个， $\dots$ ，任意 n 个事件的积事件的概率，都等于各事件概率之积，则称事件 $A_1, A_2, \dots, A_n$ 相互独立。

推论 若事件 $A_1, A_2, \dots, A_n$ ($n \geq 2$) 相互独立，则其中任意 k 个事件也是相互独立的。

若 n 个事件 $A_1, A_2, \dots, A_n$ ($n \geq 2$) 相互独立，则将 $A_1, A_2, \dots, A_n$ 中任意多个事件换成它们各自的对立事件，所得的 n 个事件仍相互独立。

独立重复试验

在同样的条件下重复地、相互独立地进行的一种随机试验，又称伯努利试验；它有两个特点：

1, 每次试验只有两种可能结果: 发生或者不发生

2, 每次试验结果互不影响

设在一次试验中, 事件 A 发生的概率为 p ($0 < p < 1$), 则在 n 重伯努利试验中, 事件 A 恰好发生 k 次的概率为

$$P_n(k) = C_n^k p^k (1 - p)^{n-k}$$

二、随机变量及其分布

2.1 随机变量及其分布函数

大纲要求

理解随机变量的概念,

理解分布函数的概念及性质,

会计算与随机变量相联系的事件的概率.

随机变量

引入一个法则, 将随机试验的每一个结果, 即将 S 的每一个元素 e 与实数 x 对应起来。

设随机试验的样本空间为 $S = \{e\}$. $X = X(e)$ 是定义在样本空间 S 上的实值单值函数。称 $X = X(e)$ 为**随机变量**。

一般用大写字母 $X, Y, Z, W, \dots$ 表示随机变量, 而以小写字母 $x, y, z, w, \dots$ 表示实数.

一般, 若 L 是一个实数集合, 将 X 在 L 上的取值写成 $\{X \in L\}$ 。它表示事件 $B = \{e|X(e) \in L\}$, 即 B 是由 S 中使得 $X(e) \in L$ 的所有样本点 e 所组成的事件, 此时有:

$$P(X \in L) = P(B) = P\{e|X(e) \in L\}$$

随机变量的取值随试验的结果而定, 而试验的各个结果出现有一定的概率, 因而随机变量的取值有一定的概率。

随机变量分两种类型, 离散型, 连续型。

随机变量的分布函数

设 X 是一个随机变量， x 是任意实数，函数

$$F(x) = P\{X \leq x\}, \quad -\infty < x < \infty$$

称为 X 的分布函数。

对于任意实数 x_1, x_2 ($x_1 < x_2$)，有

$$P(x_1 < X \leq x_2) = P(X \leq x_2) - P(X \leq x_1) = F(x_2) - F(x_1)$$

如果已知 X 的分布函数，可得任一区间 $(x_1, x_2]$ 上的概率。从这个意义上来说，分布函数完整地描述了随机变量的统计规律性。

分布函数的性质

1, $F(x)$ 是一个不减函数。对于任意实数 x_1, x_2 ($x_1 < x_2$)，有

$$F(x_2) - F(x_1) = P(x_1 < X \leq x_2) \geq 0$$

2, $0 \leq F(x) \leq 1$ ，且

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, \quad F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$$

3, $F(x+0) = F(x)$ ，即 $F(x)$ 是右连续的。

2.2 离散型随机变量及其概率分布

大纲要求

理解离散型随机变量及其概率分布的概念，

掌握0-1分布、二项分布、几何分布、超几何分布、泊松(Poisson)分布及其应用。

掌握泊松定理的结论和应用条件，

会用泊松分布近似表示二项分布。

离散型随机变量及其概率分布的概念

若随机变量可能取到的值是有限个或可列无限个, 这种随机变量称为**离散型随机变量**。

设离散型随机变量 X 所有可能取值为 x_k ($k = 1, 2, \dots$), X 取各个可能值的概率, 即事件 $\{X = x_k\}$ 的概率为

$$P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$$

上式为离散型随机变量 X 的分布律。也可以用表格的形式来表示

X	x_1	x_2	$\dots$	x_n	$\dots$
p_k	p_1	p_1	$\dots$	p_n	$\dots$

p_k 满足如下两个条件:

1, $p_k \geq 0, \quad k = 1, 2, \dots$

2, $\sum_{k=1}^{\infty} p_k = 1$

离散型随机变量的分布函数为

$$F(x) = P\{X \leq x\} = \sum_{x_k \leq x} P\{X = x_k\}$$

即

$$F(x) = \sum_{x_k \leq x} p_k$$

这里的和式是对于所有满足 $x_k \leq x$ 的 k 求和的。分布函数在 $x = x_k$ ($k = 1, 2, \dots$) 处有跳跃, 其跳跃值为 $p_k = P\{X = x_k\}$ 。

常见离散型随机变量

0-1 分布

随机变量 X 只可能取 0 与 1 两个值，它的分布律是

$$P\{X = k\} = p^k(1 - p)^{1-k}, \quad k = 0, 1 \quad (0 < p < 1)$$

则称 X 服从以 p 为参数的 **0-1 分布**。

0-1 分布的分布律，表格形式

X	0	1
p_k	$1 - p$	p

伯努利试验、二项分布

设试验 E 只有两个可能结果： A 与 $\bar{A}$ ，称 E 为伯努利试验。设 $P\{A\} = p$ ($0 < p < 1$)，此时 $P\{\bar{A}\} = 1 - p$ 。将 E 独立重复的进行 n 次，则称这一串重复的独立试验为 **n 重伯努利试验**。

记 $q = 1 - p$ ，在 n 次试验中 A 发生 k 次的概率为：

$$P\{X = k\} = C_n^k p^k q^{n-k}, \quad k = 0, 1, 2, \dots, n$$

$C_n^k p^k q^{n-k}$ 刚好是二项式 $(p + q)^n$ 展开式中出现 p^k 的那一项，我们称随机变量 X 服从参数为 n, p 的二项分布，并记为 $X \sim b(n, p)$ 。

当 n 为 1 时，此时就是 0-1 分布

伯努利试验告诉我们，一个事件尽管在一次试验中发生的概率很小，但是只要试验次数很多，而且试验是独立进行的，那么这一事件的发生几乎是肯定的。

几何分布

概率为 p 的事件 A ，以 X 记 A 首次发生所进行的试验次数，则 X 的分布列：

$$P\{X = k\} = (1 - p)^{k-1}p$$

具有这种分布列的随机变量 X ，称为服从参数 p 的**几何分布**，记为 $X \sim Geo(p)$

伯努利试验的变体。

超几何分布

设有 N 件产品，其中有 D 件次品，从中任取 n 件，其中恰有 k 件次品的概率：

$$P(A) = \frac{C_D^k C_{N-D}^{n-k}}{C_N^n}$$

泊松分布

设随机变量 X 所有可能取的值为 $0, 1, 2, \dots$ ，而取各个值的概率为

$$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 是常数。则称随机变量 X 服从参数为 λ 的泊松分布（Poisson），记为 $X \sim \pi(\lambda)$ ，或 $X \sim P(\lambda)$ 。

泊松定理

设 $\lambda > 0$ 是一个常数， n 是任意正整数，设 $np_n = \lambda$ ，则对任一固定的非负整数 k ，有

$$\lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

这个定理说明，当 n 很大， p 很小($np = \lambda$)时，则可以用近似公式

$$C_n^k p^k (1 - p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}$$

2.3 连续型随机变量及其概率密度

大纲要求

理解连续型随机变量及其概率密度的概念,

掌握均匀分布、正态分布、指数分布及其应用, 其中参数为 $\lambda(\lambda>0)$ 的指数分布 $E(\lambda)$

的概率密度为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$

连续型随机变量及其概率密度

如果对于随机变量 X 的分布函数 $F(x)$, 存在非负可积函数 $f(x)$,使对于任意实数 x , 有

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称 X 为**连续型随机变量**, $f(x)$ 称为 X 的**概率密度函数**, 简称**概率密度**。

概率密度 $f(x)$ 具有以下性质:

1, $f(x) \geq 0$

2, $\int_{-\infty}^{\infty} f(x) dx = 1$

3, 对于任意实数 x_1, x_2 ($x_1 < x_2$), 有

$$P(x_1 < X \leq x_2) = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x) dx$$

4, 若 $F(x)$ 在点 x 连续, 则有 $F'(x) = f(x)$

X 落在小区间 $(x, x + \Delta x]$ 的概率近似的有

$$P(x < X \leq x + \Delta x) \approx f(x)\Delta x$$

对于连续型随机变量 X 来说, 它取任一指定实数值 a 的概率均为 0,即

$$P(X = a) = 0$$

$P(A) = 0$ 并不意味着 A 是不可能事件。

在计算连续型随机变量落在某一区间的概率时, 可以不必区分该区间是开区间还是闭区间, 还是半闭区间。

$$P(a < X \leq b) = P(a \leq X \leq b) = P(a < X < b)$$

常见的连续性随机变量的分布

均匀分布

若连续型随机变量 X 具有概率密度

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

则称 X 在区间 (a, b) 上服从均匀分布, 记为 $X \sim U(a, b)$ 。

它的分布函数为:

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

随机变量 X 落在 (a, b) 的小区间的概率只依赖于子区间的长度, 而与小区间的位置无关。这符合几何概型的情形。

指数分布

若连续型随机变量 X 的概率密度为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$$

其中 $\lambda > 0$ 为常数, 则称 X 服从参数为 λ 的指数分布。 λ 是率参数, 表示单位时间内事件发生的平均次数。

注意: 教材给出的形式有所不同, 若连续型随机变量 X 的概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0 \\ 0, & \text{其他} \end{cases}$$

其中 $\theta > 0$ 为常数, 则称 X 服从参数为 θ 的指数分布。 θ 指的是某一事件的等待时间。

这里以考研大纲为准。

它的分布函数为:

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$$

指数函数具有无记忆性的特点。对于任意 $s, t > 0$ 有:

$$P\{X > s + t \mid X > s\} = P\{X > t\}$$

这是一个永葆青春的分佈。

正态分布

若连续型随机变量 X 的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-u)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

其中 u, σ 为常数, 则称 X 服从参数为 u, σ 的正态分布(也叫高斯分布), 记为

$X \sim N(u, \sigma^2)$.

正态分布概率密度 $f(x)$ 图形具有以下性质:

1, 曲线关于 $x = u$ 对称。对于任意 $h > 0$ 有,

$$P\{u - h < X \leq u\} = P\{u < X \leq u + h\}$$
$$P\{X \leq u\} = F(u) = 1 - F(u) = \frac{1}{2}$$

2, 当 $x = u$ 时取得最大值。

$$f(u) = \frac{1}{\sqrt{2\pi}\sigma}$$

3, 在 $x = u \pm \sigma$ 处, 曲线有拐点。曲线以 Ox 轴为渐近线

它的分布函数为

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-u)^2}{2\sigma^2}} dt$$

标准正态分布

当 $u = 0$, $\sigma = 1$ 时, 称随机变量 X 服从**标准正态分布**, 其概率密度和分布函数分别用 $\varphi(x)$, $\Phi(x)$ 表示, 即有:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$
$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt$$

易知 $\Phi(-x) = 1 - \Phi(x)$

人们制作了 $\Phi(x)$ 的函数表, 可供查用。

引理 若随机变量 $X \sim N(u, \sigma^2)$, 则 $Z = \frac{X-u}{\sigma} \sim N(0,1)$

普通正态分布转标准表示：

$$F(x) = P\{X \leq x\} = P\left\{\frac{X-u}{\sigma} \leq \frac{x-u}{\sigma}\right\} = \Phi\left(\frac{x-u}{\sigma}\right)$$

对于任意区间 $(x_1, x_2]$,有

$$P\{x_1 < X \leq x_2\} = P\left\{\frac{x_1-u}{\sigma} < \frac{X-u}{\sigma} \leq \frac{x_2-u}{\sigma}\right\} = \Phi\left(\frac{x_2-u}{\sigma}\right) - \Phi\left(\frac{x_1-u}{\sigma}\right)$$

上 α 分位数

设 $X \sim N(0,1)$, 若 z_α 满足条件

$$P\{X > z_\alpha\} = \alpha, \quad 0 < \alpha < 1$$

则称 z_α 为标准正态分布的上 α 分位数。

易知 $z_{1-\alpha} = -z_\alpha$

2.4 随机变量函数的分布

大纲要求

会求随机变量函数的分布

求解方法

已知随机变量 X 的概率分布，去求它的 $Y = g(x)$ 的概率分布。

方法：与 Y 有关的事件转化成 X 的事件

离散型

由已知函数 $g(x)$ 可求出 Y 的所有可能取值，则 Y 的概率分布

$$P\{Y = y_i\} = \sum_{k: g(x_k)=y_i} p_k$$
$$i = 1, 2, \dots$$

连续型

公式 设随机变量 X 具有概率密度 $f_X(x)$, $-\infty < x < \infty$, 又设函数 $g(x)$ 处处可导且恒有 $g'(x) > 0$ (或恒有 $g'(x) < 0$), 则 $Y = g(x)$ 是连续型随机变量, 其概率密度为

$$f_Y(y) = \begin{cases} f_X(h(y))h'(y), & \alpha < y < \beta \\ 0, & \text{其他} \end{cases}$$

其中 $\alpha = \min\{g(-\infty), g(\infty)\}$, $\beta = \max\{g(-\infty), g(\infty)\}$, $h(y)$ 是 $g(x)$ 的反函数。

这个公式的使用需要注意条件。

方法二：从分布函数出发，求分布函数，再求导。分两种情况：

- 1, 求出分布函数,
- 2, 求出分布函数的关系式, 求导

例如 已知 $f_X(x)$ 的概率密度, 求 $Y = X^2$ 的

$$F_Y(y) = P\{Y \leq y\} = P\{X^2 \leq y\} = P\{-\sqrt{y} \leq X \leq \sqrt{y}\} = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

到此, 直接求导, 无需求出 $F_Y(y)$, 即可得到 $f_Y(y)$

三、多维随机变量及其分布

3.1 多维随机变量及分布

大纲要求

理解 多维随机变量的概念,

理解多维随机变量的分布的概念和性质,

理解二维离散型随机变量的概率分布、边缘分布和条件分布,

理解二维连续型随机变量的概率密度、边缘密度和条件密度,

会求与二维随机变量相关事件的概率。

多维随机变量

二维随机变量

一般, 设 E 是一个随机试验, 它的样本空间是 $S = \{e\}$, $X = X(e)$ 和 $Y = Y(e)$ 是定义在 S 上的随机变量, 由它们构成的一个向量 (X, Y) , 叫做**二维随机变量**(二维随机向量)。

定义推广:

一般, 设 E 是一个随机试验, 它的样本空间是 $S = \{e\}$, $X_1 = X_1(e)$, $X_2 = X_2(e)$, $\dots$, $X_n = X_n(e)$ 是定义在 S 上的随机变量, 由它们构成的一个 n 维向量 $(X_1, X_2, \dots, X_n)$, 称为 **n 维随机变量**(n 维随机向量)。

多维随机变量的分布的概念和性质

二维随机变量的分布函数

设 (X, Y) 是二维随机变量, 对于任何实数 x, y , 二元函数

$$F(x, y) = P\{(X \leq x) \cap (Y \leq y)\} \overset{\text{记成}}{\Longleftrightarrow} P\{X \leq x, Y \leq y\}$$

称为**二维随机变量 (X, Y) 的分布函数**, 或称为随机变量 X 和 Y 的**联合分布函数**。

推广:

对于任意 n 个实数 $x_1, x_2, \dots, x_n$, n 元函数

$$F(x_1, x_2, \dots, x_n) = P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\}$$

称为 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的分布函数, 或随机变量 $X_1, X_2, \dots, X_n$ 的**联合分布函数**。

分布函数 $F(x, y)$ 的基本性质:

1, $F(x, y)$ 是变量 x 和 y 的不减函数。即对于任意固定的 y , 当 $x_2 > x_1$ 时, $F(x_2, y) \geq F(x_1, y)$; 对于任意固定的 x , 当 $y_2 > y_1$ 时, $F(x, y_2) \geq F(x, y_1)$ 。

2, $0 \leq F(x, y) \leq 1$, 且

对于任意固定的 y , $F(-\infty, y) = 0$,

对于任意固定的 x , $F(x, -\infty) = 0$,

$F(-\infty, -\infty) = 0$, $F(\infty, \infty) = 1$

3, $F(x+0, y) = F(x, y)$, $F(x, y+0) = F(x, y)$, 即 $F(x, y)$ 关于 x 右连续, 关于 y 也右连续

4, 对于任意的 (x_1, y_1) , (x_2, y_2) , $x_1 < x_2$, $y_1 < y_2$, 下述不等式成立

$$F(x_2, y_2) - F(x_2, y_1) + F(x_1, y_1) - F(x_1, y_2) \geq 0$$

边缘分布

二维随机变量 (X, Y) 作为一个整体, 具有分布函数 $F(x, y)$ 。而 X 和 Y 都是随机变量, 各自也有分布函数, 将它们分别记为 $F_X(x)$, $F_Y(y)$, 依次称为二维随机变量 (X, Y) 关于 X 和关于 Y 的**边缘分布函数**。

$$F_X(x) = P\{X \leq x\} = P\{X \leq x, Y < \infty\} = F(x, \infty)$$

$$F_X(x) = F(x, \infty)$$

$$F_Y(y) = F(\infty, y)$$

二维离散型随机变量

如果二维随机变量 (X, Y) 全部可能取到的值是有限对或可列无限多对，则称 (X, Y) 是**二维离散型随机变量**。

设二维离散型随机变量 (X, Y) 所有可能取到的值为 (x_i, y_j) , $i, j = 1, 2, \dots$ ，记

$$P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$$

则由概率的定义有：

$$p_{ij} \geq 0, \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} p_{ij} = 1$$

我们称 $P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$ 为二维离散型随机变量 (X, Y) 的分布律，或称为随机变量 X, Y 的联合分布律。

它的分布函数为

$$F(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij}$$

其中和式是对一切满足 $x_i \leq x$, $y_j \leq y$ 的 i, j 来求和的。

二维离散型随机变量的边缘分布

X 的分布律为： $P\{X = x_i\} = \sum_{j=1}^{\infty} p_{ij}, i = 1, 2, \dots$

Y 的分布律为： $P\{Y = y_j\} = \sum_{i=1}^{\infty} p_{ij}, j = 1, 2, \dots$

记 $p_{i\cdot} = \sum_{j=1}^{\infty} p_{ij} = P\{X = x_i\}, i = 1, 2, \dots$

记 $p_{\cdot j} = \sum_{i=1}^{\infty} p_{ij} = P\{Y = y_j\}, j = 1, 2, \dots$

分别称 $p_{i\cdot}$ ($i = 1, 2, \dots$) $p_{\cdot j}$ ($j = 1, 2, \dots$)为 (X, Y) 关于 X 和关于 Y 的边缘分布律

二维离散型随机变量的条件分布

由条件概率自然的引出条件概率分布的概念。

设 (X, Y) 是二维离散型随机变量，对于固定的 j ，若 $P\{Y = y_j\} > 0$ ，则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{\cdot j}}, i = 1, 2, \dots$$

为在 $Y = y_j$ 条件下**随机变量 X 的条件分布律**

对于固定的 i ，若 $P\{X = x_i\} > 0$ ，则称

$$P\{Y = y_j | X = x_i\} = \frac{P\{X = x_i, Y = y_j\}}{P\{X = x_i\}} = \frac{p_{ij}}{p_{i \cdot}}, j = 1, 2, \dots$$

为在 $X = x_i$ 条件下**随机变量 Y 的条件分布律**

二维连续型随机变量

概率密度

如果对于二维随机变量 (X, Y) 的分布函数 $F(x, y)$ ，如果存在非负可积函数 $f(x, y)$ ，使对于任意 x, y 有

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) \, du \, dv$$

则称 (X, Y) 是**二维连续型随机变量**，函数 $f(x, y)$ 称为二维连续型随机变量 (X, Y) 的**概率密度**，或称为随机变量 X 和 Y 的**联合概率密度**。

概率密度 $f(x, y)$ 具有以下性质：

1, $f(x, y) \geq 0$

2, $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) \, dx \, dy = 1$

3, 设是 G 平面 xOy 上的区域，点 (X, Y) 落在 G 内的概率为

$$P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy$$

4, 若 $f(x, y)$ 在点 (x, y) 连续, 则有

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

在几何上, $z = f(x, y)$ 表示空间的一个曲面, 介于它和 xOy 平面的空间区域的体积为 1.

边缘密度

对于连续型随机变量 (X, Y) , 设它的概率密度为 $f(x, y)$, 有

$$F_X(x) = F(x, \infty) = \int_{-\infty}^x \left[\int_{-\infty}^{\infty} f(x, y) dy \right] dx$$

X 是一个连续型随机变量, 且其概率密度为

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

同样, Y 也是一个连续型随机变量, 其概率密度为

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

分别称 $f_X(x)$ 、 $f_Y(y)$ 为 (X, Y) 关于 X 和关于 Y 的**边缘概率密度**。

条件密度

设二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, (X, Y) 关于 Y 的边缘概率密度 $f_Y(y)$ 。若对于固定的 y , $f_Y(y) > 0$, 则称 $\frac{f(x, y)}{f_Y(y)}$ 为在 $Y = y$ 的条件下 X 的**条件概率密度**, 记为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

称 $\int_{-\infty}^x f_{X|Y}(x|y) dx = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$ 为在 $Y = y$ 的条件下 X 的**条件分布函数**, 记为

$P\{X \leq x | Y = y\}$ 或 $F_{X|Y}(x|y)$, 即:

$$F_{X|Y}(x|y) = P\{X \leq x | Y = y\} = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$$

类似的可以定义:

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$$
$$F_{Y|X}(y|x) = \int_{-\infty}^y \frac{f(x, y)}{f_X(x)} dy$$

二维随机变量相关事件的概率的求法

依照二维离散型随机变量的概率分布、边缘分布和条件分布, 二维连续型随机变量的概率密度、边缘密度和条件密度。按照里面的公式, 求解即可。

3.2 随机变量的独立性及不相关性

大纲要求

理解随机变量的独立性及不相关性的概念,

掌握随机变量相互独立的条件

随机变量的独立性

设 $F(x, y)$ 及 $F_X(x)$, $F_Y(y)$ 分别是二维随机变量 (X, Y) 的分布函数及边缘分布函数。若对于所有 x, y 有

$$P\{X \leq x, Y \leq y\} = P\{X \leq x\}P\{Y \leq y\}$$

即 $F(x, y) = F_X(x)F_Y(y)$, 则称随机变量 X 和 Y 是**相互独立的**。

对于 n 维随机变量 $(X_1, X_2, \dots, X_n)$, 若对于所有的 $x_1, x_2, \dots, x_n$, 有

$$F(x_1, x_2, \dots, x_n) = F_{X_1}(x_1)F_{X_2}(x_2) \cdots F_{X_n}(x_n)$$

则称 $X_1, X_2, \dots, X_n$ 是相互独立的。

连续型随机变量相互独立等价于：

$$f(x, y) = f_X(x)f_Y(y)$$

在平面上几乎处处成立。（除去面积为零的集合）

离散型随机变量相互独立等价于： $P\{X = x_i, Y = y_j\} = P\{X = x_i\}P\{Y = y_j\}$

定理 $(X_1, X_2, \dots, X_m)$ 和 $(Y_1, Y_2, \dots, Y_n)$ 相互独立。则 X_i ($i = 1, 2, \dots, m$) 和 Y_j ($j = 1, 2, \dots, n$) 相互独立。又若 h, g 是连续函数，则 $h(X_1, X_2, \dots, X_m)$ 和 $g(Y_1, Y_2, \dots, Y_n)$ 相互独立。

不相关

随机变量 X 和 Y 的相关系数 $\rho_{XY} = 0$ 时，称 X 和 Y 不相关。

当 X 和 Y 相互独立时，必定不相关。当 X 和 Y 不相关时，不一定相互独立。不相关只是对线性关系来说，而相互独立是就一般关系而言的。对于二维正态分布，相互独立与不相关是等价的。

随机变量相互独立的条件

$$F(x_1, x_2, \dots, x_n) = F_{X_1}(x_1)F_{X_2}(x_2) \cdots F_{X_n}(x_n)$$

3.3 二维均匀分布和二维正态分布

大纲要求

掌握二维均匀分布，

了解二维正态分布 $N(u_1, u_2, \sigma_1^2, \sigma_2^2, \rho)$ 的概率密度, 理解其中参数的概率意义.

二维均匀分布

设 G 是平面上的有界区域, 其面积为 A , 若二维随机变量 (X, Y) 具有概率密度

$$f(x, y) = \begin{cases} \frac{1}{A}, & (x, y) \in G \\ 0, & \text{其他} \end{cases}$$

则称 (X, Y) 在 G 上服从均匀分布。

二维正态分布

设二维随机变量 (X, Y) 的概率密度为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[\frac{(x-u_1)^2}{\sigma_1^2} - 2\rho \frac{(x-u_1)(y-u_2)}{\sigma_1\sigma_2} + \frac{(y-u_2)^2}{\sigma_2^2} \right] \right\}$$

其中 $u_1, u_2, \sigma_1, \sigma_2, \rho$ 都是常数, 且 $\sigma_1 > 0, \sigma_2 > 0, -1 < \rho < 1$. 我们称 (X, Y) 为服从参数 $u_1, u_2, \sigma_1, \sigma_2, \rho$ 的二维正态分布。记为 $(X, Y) \sim N(u_1, u_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

这里的 u_1, u_2 表示的是数学期望, σ_1, σ_2 表示的是均方差, ρ 表示的相关系数。

边缘分布:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-u_1)^2}{2\sigma_1^2}}, \quad -\infty < x < \infty$$
$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-u_2)^2}{2\sigma_2^2}}, \quad -\infty < y < \infty$$

这两个边缘分布都是一维正态分布, 不依赖于参数 ρ 。

当 $\rho = 0$ 时, 二维正态分布有: $f(x, y) = f_X(x)f_Y(y)$

3.4 两个随机变量的函数的分布

大纲要求

会求两个随机变量简单函数的分布,

会求多个相互独立随机变量简单函数的分布

$Z = X + Y$ 的分布

设 (X, Y) 是二维连续型随机变量, 它具有概率密度 $f(x, y)$ 。则 $Z = X + Y$ 仍为连续型随机变量, 其概率密度为

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(z-y, y) dy$$

或

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(x, z-x) dx$$

如果 X 和 Y 相互独立, (X, Y) 关于 X, Y 的边缘概率密度分别为 $f_X(x)$, $f_Y(y)$ 。上述公式可化为:

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$$

和

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

这两个公式称为 f_X 和 f_Y 的卷积公式, 记为 $f_X * f_Y$, 即

$$f_X * f_Y = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

一般的, 设 X 和 Y 相互独立, 且 $X \sim N(u_1, \sigma_1^2)$, $Y \sim N(u_2, \sigma_2^2)$, $Z = X + Y$ 仍然服从正态分布, 且有 $Z \sim N(u_1 + u_2, \sigma_1^2 + \sigma_2^2)$ 。

这个结论可以推广为：有限个相互独立的正态随机变量的线性组合仍然服从正态分布。

Γ 分布的概率密度

$$f(x) = \begin{cases} \frac{1}{\theta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta}, & x > 0 \\ 0, & \text{其他} \end{cases} \quad \alpha > 0, \theta > 0$$

若 $X_1, X_2, \dots, X_n$ 相互独立，且 X_i 服从参数为 α_i, β ($i = 1, 2, \dots, n$)的 Γ 分布。则 $\sum_{i=1}^n X_i$ 服从参数为 $\sum_{i=1}^n \alpha_i, \beta$ 的 Γ 分布。这一性质也叫 Γ 分布的可加性。

$Z = \frac{Y}{X}$ 的分布、 $Z = XY$ 的分布

设 (X, Y) 是二维连续型随机变量，它具有概率密度 $f(x, y)$ 。则 $Z = \frac{Y}{X}$, $Z = XY$ 仍为连续型随机变量，其概率密度分别为

$$f_{Y/X}(z) = \int_{-\infty}^{\infty} |x| f(x, xz) dx$$

$$f_{XY}(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f\left(x, \frac{z}{x}\right) dx$$

如果 X 和 Y 相互独立， (X, Y) 关于 X, Y 的边缘概率密度分别为 $f_X(x)$, $f_Y(y)$ 。上述公式可化为：

$$f_{Y/X}(z) = \int_{-\infty}^{\infty} |x| f_X(x) f_Y(xz) dx$$

$$f_{XY}(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f_X(x) f_Y\left(\frac{z}{x}\right) dx$$

$M = \max\{X, Y\}$ 及 $N = \min\{X, Y\}$ 的分布

设 X, Y 是两个相互独立的随机变量，它们的分布函数分别为 $F_X(x)$ 和 $F_Y(y)$

$$F_{\max}(z) = P\{M \leq z\} = P\{X \leq z, Y \leq z\} = P\{X \leq z\}P\{Y \leq z\}$$

即有

$$F_{\max}(z) = F_X(z)F_Y(z)$$

$$\begin{aligned} F_{\min}(z) &= P\{N \leq z\} = 1 - P\{N > z\} = 1 - P\{X > z, Y > z\} \\ &= 1 - P\{X > z\}P\{Y > z\} \end{aligned}$$

即有

$$F_{\min}(z) = 1 - [1 - F_X(z)][1 - F_Y(z)]$$

上述结果可以进一步推广。

设 $X_1, X_2, \dots, X_n$ 是 n 个相互独立的随机变量，它们的分布函数分别为 $F_{X_i}(x_i)$ ($i = 1, 2, \dots, n$), 则 $M = \max\{X_1, X_2, \dots, X_n\}$ 及 $N = \min\{X_1, X_2, \dots, X_n\}$ 的分布函数分别为

$$F_{\max}(z) = F_{X_1}(z)F_{X_2}(z) \cdots F_{X_n}(z)$$

$$F_{\min}(z) = 1 - [1 - F_{X_1}(z)][1 - F_{X_2}(z)] \cdots [1 - F_{X_n}(z)]$$

特别的当 $X_1, X_2, \dots, X_n$ 相互独立且具有相同分布函数 $F(x)$ ，有

$$\begin{aligned} F_{\max}(z) &= [F(z)]^n \\ F_{\min}(z) &= 1 - [1 - F(z)]^n \end{aligned}$$

四、随机变量的数字特征

4.1 随机变量数字特征

大纲要求

理解随机变量数字特征(数学期望、方差、标准差、矩、协方差、相关系数)的概念,

会运用数字特征的基本性质,

并掌握常用分布的数字特征.

数学期望

设离散型随机变量 X 的分布律为

$$P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$$

若级数

$$\sum_{k=1}^{\infty} x_k p_k$$

绝对收敛, 则称级数 $\sum_{k=1}^{\infty} x_k p_k$ 的和为随机变量 X 的**数学期望**, 记为 $E(X)$. 即

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

设连续型随机变量 X 的概率密度为 $f(x)$, 若积分

$$\int_{-\infty}^{\infty} x f(x) dx$$

绝对收敛, 则称积分 $\int_{-\infty}^{\infty} x f(x) dx$ 的值为随机变量 X 的**数学期望**, 记为 $E(X)$. 即

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

数学期望简称期望，又称为均值。数学期望 $E(X)$ 完全由随机变量 X 的概率分布所确定，若 X 服从某一分布，也称 $E(X)$ 是这一分布的数学期望。

数学期望的基本性质

1, 设 C 是常数, 则有 $E(C) = C$

2, 设 X 是一个随机变量, C 是常数, 则有 $E(CX) = CE(X)$

3, 设 X, Y 是两个随机变量, 则有 $E(X + Y) = E(X) + E(Y)$

这一性质可以推广到任意有限个随机变量之和的情况

4, 设 X, Y 是相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y)$$

这一性质可以推广到任意有限个相互独立的随机变量之积的情况

方差

设 X 是随机变量, 若 $E\{[X - E(X)]^2\}$ 存在, 则称它为 X 的方差, 记为 $D(X)$ 或 $\text{Var}(X)$, 即

$$D(X) = \text{Var}(X) = E\{[X - E(X)]^2\}$$

应用上还引入量 $\sqrt{D(X)}$, 记为 $\sigma(X)$, 称为**标准差**或**均方差**

随机变量 X 的方差表达了 X 取值与其数学期望的**偏离程度**。 $D(X)$ 是刻画 X 取值分散程度的一个量, 它是衡量 X 取值分散程度的一个尺度。

对于离散型随机变量有:

$$D(X) = \sum_{k=1}^{\infty} [x_k - E(X)]^2 p_k$$

其中 $P\{X = x_k\} = p_k$, $k = 1, 2, \dots$ 是 X 的分布律。

对于连续型随机变量有

$$D(X) = \int_{-\infty}^{\infty} [x - E(X)]^2 f(x) dx$$

其中 $f(x)$ 是 X 的概率密度。

方差的基本性质

1, 设 C 是常数, 则有 $D(C) = 0$

2, 设 X 是一个随机变量, C 是常数, 则有

$$D(CX) = C^2 D(X) \quad D(X + C) = D(X)$$

3, 设 X, Y 是两个随机变量, 则有

$$D(X + Y) = D(X) + D(Y) + 2E\{[X - E(X)][Y - E(Y)]\}$$

特别的, 若 X, Y 相互独立, 则有 $D(X + Y) = D(X) + D(Y)$

4, $D(X) = 0$ 的充要条件是 X 以概率 1 取常数 $E(X)$, 即

$$P\{X = E(X)\} = 1$$

协方差及相关系数

量 $E\{[X - E(X)][Y - E(Y)]\}$ 称为随机变量 X 与 Y 的**协方差**, 记为 $\text{Cov}(X, Y)$, 即

$$\text{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

而 $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$ 称为随机变量 X 与 Y 的**相关系数**。

协方差的性质

1, $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$, a, b 是常数

$$2, \text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

相关系数的性质

$$1, |\rho_{XY}| \leq 1$$

2, $|\rho_{XY}| = 1$ 的充要条件是, 存在常数 a, b , 使

$$P\{Y = a + bX\} = 1$$

当 $|\rho_{XY}| = 1$ 时, X 和 Y 之间以概率 1 存在着线性关系。当 $|\rho_{XY}|$ 较大时, 我们通常说 X, Y 线性相关的程度较好; 当 $|\rho_{XY}|$ 较小时, 我们通常说 X, Y 线性相关的程度较差。当 $|\rho_{XY}| = 0$ 时, 称 X 和 Y 不相关。

当 X 和 Y 相互独立时, 必定不相关。当 X 和 Y 不相关时, 不一定相互独立。不相关只是对线性关系来说, 而相互独立是就一般关系而言的。对于二维正态分布, 相互独立与不相关是等价的。

矩、协方差矩阵

设 X 和 Y 是随机变量, 若

$$E(X^k), \quad k = 1, 2, \dots$$

存在, 称它为 X 的 k 阶原点矩, 简称 k 阶矩。

若

$$E\{[X - E(X)]^k\}, \quad k = 2, 3, \dots$$

存在, 称它为 X 的 k 阶中心矩。

若

$$E(X^k Y^l), \quad k, l = 1, 2, \dots$$

存在，称它为 X 和 Y 的 $k + l$ 阶混合矩。

若

$$E\{[X - E(X)]^k [Y - E(Y)]^l\}, \quad k, l = 1, 2, \dots$$

存在，称它为 X 和 Y 的 $k + l$ 阶混合中心矩。

由定义可知，数学期望 $E(X)$ 是 X 的一阶原点矩，方差 $D(X)$ 是 X 的二阶中心矩，协方差 $\text{Cov}(X, Y)$ 是 X 和 Y 的二阶混合中心矩。

二维随机变量 (X_1, X_2) 有四个二阶中心矩(设它们都存在)，分别记为：

$$\begin{aligned} c_{11} &= E\{[X_1 - E(X_1)]^2\} \\ c_{12} &= E\{[X_1 - E(X_1)][X_2 - E(X_2)]\} \\ c_{21} &= E\{[X_2 - E(X_2)][X_1 - E(X_1)]\} \\ c_{22} &= E\{[X_2 - E(X_2)]^2\} \end{aligned}$$

将它们排列称矩阵的形式：

$$\begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{pmatrix}$$

这个矩阵称为随机变量 (X_1, X_2) 的协方差矩阵

设 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的二阶混合中心矩

$$c_{ij} = \text{Cov}(X_i, X_j) = E\{[X_i - E(X_i)][X_j - E(X_j)]\}, \quad i, j = 1, 2, \dots, n$$

都存在，则称矩阵

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

为 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵。由于 $c_{ij} = c_{ji} (i \neq j; i, j = 1, 2, \dots, n)$,

因而这个矩阵是对称矩阵。

引入矩阵

$$\mathbf{X} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} = \begin{pmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_n) \end{pmatrix}$$

n 维正态随机变量 $(X_1, X_2, \dots, X_n)$ 的概率密度定义为:

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{n/2}(\det C)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{X} - \mathbf{u})^T \mathbf{C}^{-1}(\mathbf{X} - \mathbf{u})\right\}$$

常用分布的数字特征

常用分布	分布律	期望 $E(X)$	方差 $D(X)$
泊松分布 $X \sim \pi(\lambda)$	$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ
均匀分布 $X \sim U(a, b)$	$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布 $X \sim N(u, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-u)^2}{2\sigma^2}}$	u	σ^2
二项分布(伯努利) $X \sim b(n, p)$	$P\{X = k\} = C_n^k p^k q^{n-k}$	np	$np(1-p)$
指数分布	$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

4.2 随机变量函数的数学期望

大纲要求

会求随机变量函数的数学期望

随机变量函数的数学期望

设 Y 是随机变量 X 的函数： $Y = g(X)$ (g 是连续函数)。

1, 如果 X 是离散型随机变量, 它的分布律为 $P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$, 若 $\sum_{k=1}^{\infty} g(x_k)p_k$ 绝对收敛, 则有

$$E(Y) = E[g(X)] = \sum_{k=1}^{\infty} g(x_k)p_k$$

2, 如果 X 是连续型随机变量, 它的概率密度为 $f(x)$, 若 $\int_{-\infty}^{\infty} g(x)f(x) dx$ 绝对收敛, 则有

$$E(Y) = E[g(X)] = \int_{-\infty}^{\infty} g(x)f(x) dx$$

我们要求 $E(Y)$, 不必算出 Y 的分布律或概率密度, 只需要利用 X 的分布律或概率密度就可以了。

上述定理可以推广到两个或两个以上随机变量的函数的情况。

设 Z 是随机变量 X, Y 的函数： $Z = g(X, Y)$ (g 是连续函数)。那么 Z 是一个一维随机变量。若二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, 则有：

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y)f(x, y) dx dy$$

这里设上式右边的积分绝对收敛。

又若 (X, Y) 是离散型随机变量, 其分布律为 $P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$, 则有

$$E(Z) = E[g(X, Y)] = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} g(x_i, y_j)p_{ij}$$

这里设上式右边的级数绝对收敛。

五、大数定律和中心极限定理

5.1 切比雪夫不等式

大纲要求

了解切比雪夫不等式

切比雪夫不等式

设随机变量 X 具有数学期望 $E(X) = u$, 方差 $D(X) = \sigma^2$, 则对于任意整数, 不等式

$$P\{|X - u| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

成立。

这一不等式称为**切比雪夫不等式**(Chebyshev)

它也可以写成如下形式:

$$P\{|X - u| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

这个不等式给出了, 在随机变量的分布函数未知, 而只知道 $E(X)$ 和 $D(X)$ 的情况下估计概率 $P\{|X - u| < \varepsilon\}$ 的界限。这个估计是比较粗糙的。

5.2 大数定律

大纲要求

了解切比雪夫大数定律、伯努利大数定律和辛钦大数定律 (独立同分布随机变量序列的大数定律)

切比雪夫大数定律

设 $X_1, X_2, \dots$ 是相互独立的随机变量序列，且具有相同的数学期望 $E(X_k) = u$ 和方差 $D(X_k) = \sigma^2$ ($k = 1, 2, \dots$)，作前 n 个变量的算术平均 $\frac{1}{n} \sum_{k=1}^n X_k$ ，则对于任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - u \right| < \varepsilon \right\} = 1$$

伯努利大数定律

设 f_A 是 n 次独立重复试验中事件 A 发生的次数， p 是事件 A 在每次试验中发生的概率，则对于任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| < \varepsilon \right\} = 1$$

或：

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| \geq \varepsilon \right\} = 0$$

这个定律说明，当 n 充分大时，“频率 $\frac{f_A}{n}$ 与概率 p 的偏差小于 ε ”实际上是必定要发生的。这就是我们说的频率稳定性的真正含义。

辛钦大数定律

设 $X_1, X_2, \dots$ 是相互独立，服从同一分布的随机变量序列，且具有相同的数学期望 $E(X_k) = u$ ($k = 1, 2, \dots$)，作前 n 个变量的算术平均 $\frac{1}{n} \sum_{k=1}^n X_k$ ，则对于任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - u \right| < \varepsilon \right\} = 1$$

设 $Y_1, Y_2, \dots, Y_n \dots$ 是一个随机变量序列, a 是一个常数, 若对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P\{|Y_n - a| < \varepsilon\} = 1$$

则称序列 $Y_1, Y_2, \dots, Y_n \dots$ 依概率收敛于 a , 记作

$$Y_n \xrightarrow{P} a$$

辛钦大数定律又可表述为:

设随机变量 $X_1, X_2, \dots, X_n \dots$ 相互独立, 服从同一分布且具有相同的数学期望

$E(X_k) = u \ (k = 1, 2, \dots)$, 则序列 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛于 u , 即

$$\bar{X} \xrightarrow{P} u$$

5.3 中心极限定理

大纲要求

了解 棣莫弗-拉普拉斯定理(二项分布以正态分布为极限分布)和列维-林德伯格定理(独立同分布随机变量序列的中心极限定理)

列维-林德伯格定理(独立同分布中心极限定理)

设随机变量 $X_1, X_2, \dots, X_n \dots$ 相互独立, 服从同一分布, 且具有相同的数学期望和方差: $E(X_k) = u \ D(X_k) = \sigma^2 \ (k = 1, 2, \dots)$, 则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - nu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意 x 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - nu}{\sqrt{n}\sigma} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

当 n 充分大时

$$\frac{\sum_{k=1}^n X_k - nu}{\sqrt{n}\sigma} \text{ 近似地服从 } N(0,1)$$

由于

$$\frac{\sum_{k=1}^n X_k - nu}{\sqrt{n}\sigma} = \frac{\frac{1}{n} \sum_{k=1}^n X_k - u}{\sigma/\sqrt{n}} = \frac{\bar{X} - u}{\sigma/\sqrt{n}}$$

当 n 充分大时

$$\frac{\bar{X} - u}{\sigma/\sqrt{n}} \sim N(0,1)$$

$$\bar{X} \sim N(u, \sigma^2/n)$$

均值为 u ，方差为 σ^2 的独立同分布的随机变量 $X_1, X_2, \dots, X_n$ 的算术平均 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ ，当 n 充分大时，近似的服从均值为 u ，方差为 σ^2/n 的正态分布。

棣莫弗-拉普拉斯定理(二项分布以正态分布为极限分布)

设随机变量 $\eta_n (n = 1, 2, \dots)$ 服从参数为 n, p ($0 < p < 1$)的二项分布，则对于任意 x ，有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

这是中心极限定理的特殊情况。这个定理表明，正态分布是二项分布的极限分布，当 n 充分大时，可以用上式计算二项分布的概率。

六、数理统计的基本概念

数理统计以概率论为理论基础，根据试验或观察的数据来研究随机现象。它包括如何收集、整理数据资料；如何对所得的数据资料进行分析研究，从而对所研究的对象的性质、特点作出推断。

6.1 随机样本与统计量

大纲要求

理解 总体、简单随机样本、统计量、样本均值、样本方差及样本矩的概念，其中

样本方差定义为 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

随机样本

我们将试验的全部可能观察值称为**总体**。每一个可能观察值称为**个体**。总体中所包含的个体的个数称为总体的**容量**。容量为有限的称为**有限总体**，容量为无限的称为**无限总体**。

定义 设 X 是具有分布函数 F 的随机变量，若 $X_1, X_2, \dots, X_n$ 是具有同一分布函数 F 的、**相互独立**的随机变量，则称 $X_1, X_2, \dots, X_n$ 为从分布函数 F (或总体 F ，或总体 X)得到的容量为 n 的**简单随机样本**，简称**样本**，它们的观察值 $x_1, x_2, \dots, x_n$ 称为**样本值**，又称为 X 的 n 个独立的观察值。

若 $X_1, X_2, \dots, X_n$ 为 F 的一个样本，则 $X_1, X_2, \dots, X_n$ 相互独立，且它们的分布函数都是 F ，所以 $(X_1, X_2, \dots, X_n)$ 的分布函数为

$$F^*(x_1, x_2, \cdots, x_n) = \prod_{i=1}^n F(x_i)$$

又若 X 具有概率密度 f ，则 $(X_1, X_2, \cdots, X_n)$ 的概率密度为

$$f^*(x_1, x_2, \cdots, x_n) = \prod_{i=1}^n f(x_i)$$

统计量

设 $X_1, X_2, \cdots, X_n$ 是来自总体 X 的一个样本， $g(X_1, X_2, \cdots, X_n)$ 是 $X_1, X_2, \cdots, X_n$ 的函数，若 g 中不含未知参数，则称 $g(X_1, X_2, \cdots, X_n)$ 是一个**统计量**。

因为 $X_1, X_2, \cdots, X_n$ 都是随机变量，而统计量 $g(X_1, X_2, \cdots, X_n)$ 是随机变量的函数，因此统计量是一个随机变量。设 $x_1, x_2, \cdots, x_n$ 是相应于样本 $X_1, X_2, \cdots, X_n$ 的样本值，则称 $g(x_1, x_2, \cdots, x_n)$ 是 $g(X_1, X_2, \cdots, X_n)$ 的观察值。

常用统计量

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 1, 2, \dots$$

它们的观察值分别为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$a_k = \frac{1}{n} \sum_{i=1}^n x_i^k, \quad k = 1, 2, \dots$$

$$b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, \quad k = 1, 2, \dots$$

这些观察值仍分别称为样本均值、样本方差、样本标准差、样本 k 阶原点矩、样本 k 阶中心矩。

6.2 常用抽样分布

大纲要求

了解 χ^2 分布、 t 分布和 F 分布的概念及性质,

了解 上侧 α 分位数的概念并会查表计算。

χ^2 分布

设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(0,1)$ 的样本,则称统计量

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

服从自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$.

$\chi^2(n)$ 分布的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{n/2-1} e^{-y/2}, & y > 0 \\ 0, & \text{其他} \end{cases}$$

χ^2 分布的可加性 设 $\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, 并且 χ_1^2, χ_2^2 相互独立, 则有

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$$

χ^2 分布的数学期望和方差 若 $\chi^2 \sim \chi^2(n)$, 则有

$$E(\chi^2) = n, D(\chi^2) = 2n$$

χ^2 分布的上分位数

对于给定的正数 α , $0 < \alpha < 1$, 满足条件

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{\infty} f(y)dy = \alpha$$

的 $\chi_\alpha^2(n)$ 就是分布 $\chi^2(n)$ 的上 α 分位数. 对于不同的, 上 α 分位数的值已制成表格,

可以查用。

当 n 充分大时有,

$$\chi_\alpha^2(n) \approx \frac{1}{2} (z_\alpha + \sqrt{2n-1})^2$$

其中 z_α 是标准正态分布的上 α 分位数

分位数

设连续型随机变量 X 的分布函数为 $F(x)$, 概率密度函数为 $f(x)$,

1, 对于任意整数 α ($0 < \alpha < 1$), 称满足条件

$$P\{X \leq x_{\underline{\alpha}}\} = F(x_{\underline{\alpha}}) = \int_{-\infty}^{x_{\underline{\alpha}}} f(x)dx = \alpha$$

的数 $x_{\underline{\alpha}}$ 为此分布的下 α 分位数

2, 对于任意整数 α ($0 < \alpha < 1$), 称满足条件

$$P\{X > x_{\alpha}\} = 1 - F(x_{\alpha}) = \int_{x_{\alpha}}^{\infty} f(x)dx = \alpha$$

的数 x_{α} 为此分布的上 α 分位数

特别的, 当 $\alpha = 0.5$ 时,

$$F(x_{0.5}) = F(x_{\underline{0.5}}) = 0.5$$

$x_{0.5}$ 称为此分布的中位数

t 分布

设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$,且 X, Y 相互独立, 则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 **t 分布**。记为 $t \sim t(n)$

t 分布又称为学生氏(Student)分布, $t(n)$ 分布的概率密度函数为:

$$h(t) = \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2} \quad -\infty < t < \infty$$

当 n 充分大时, t 分布近似于标准正态分布。

t 分布的上分位数

对于给定的正数 α , $0 < \alpha < 1$, 满足条件

$$P\{t > t_{\alpha}(n)\} = \int_{t_{\alpha}(n)}^{\infty} f(t)dt = \alpha$$

的 $t_{\alpha}(n)$ 就是 $t(n)$ 分布的上 α 分位数。

由定义和对称性可知 $t_{1-\alpha}(n) = -t_{\alpha}(n)$

当 n 充分大时, $t_{\alpha}(n) \approx z_{\alpha}$

F 分布

设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$,且 U, V 相互独立, 则称随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度为 (n_1, n_2) 的**F分布**。记为 $F \sim F(n_1, n_2)$ 。

$F(n_1, n_2)$ 分布的概率密度为:

$$\psi(y) = \begin{cases} \frac{\Gamma[(n_1 + n_2)/2](n_1/n_2)^{n_1/2} y^{(n_1/2)-1}}{\Gamma(n_1/2)\Gamma(n_2/2)[1 + (n_1 y/n_2)]^{(n_1+n_2)/2}}, & y > 0 \\ 0, & \text{其他} \end{cases}$$

由定义可知, 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$

F分布的上分位数

对于给定的正数 α , $0 < \alpha < 1$, 满足条件

$$P\{F > F_{\alpha}(n_1, n_2)\} = \int_{F_{\alpha}(n_1, n_2)}^{\infty} \psi(y)dy = \alpha$$

的 $F_{\alpha}(n_1, n_2)$ 就是 $F(n_1, n_2)$ 分布的上 α 分位数。

$F(n_1, n_2)$ 分布的上 α 分位数有如下重要性质:

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

6.3 正态总体的常用抽样分布

大纲要求

了解正态总体的常用抽样分布

正态总体的常用抽样分布

定理 设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(u, \sigma^2)$ 的样本, $\bar{X}$ 是样本的均值, 则有

$$\bar{X} \sim N(u, \sigma^2/n)$$

定理 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(u, \sigma^2)$ 的样本, $\bar{X}, S^2$ 分别是样本均值和样本方差, 则有

$$1, \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

2, $\bar{X}$ 与 S^2 相互独立

定理 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(u, \sigma^2)$ 的样本, $\bar{X}, S^2$ 分别是样本均值和样本方差, 则有

$$\frac{\bar{X} - u}{S/\sqrt{n}} \sim t(n-1)$$

对于两个正态总体的样本均值和样本方差有以下定理。

定理 设 $X_1, X_2, \dots, X_{n_1}$ 与 $Y_1, Y_2, \dots, Y_{n_2}$ 分别是来自正态总体 $N(u_1, \sigma_1^2)$ 和 $N(u_2, \sigma_2^2)$ 的样本, 且这两个样本相互独立。设 $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i$, $\bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i$ 分别是这两个样本的样本均值; $S_1^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2$, $S_2^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$ 分别是这两个样本的样本方差。则有

$$1, \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$2, \text{ 当 } \sigma_1^2 = \sigma_2^2 = \sigma^2 \text{ 时,}$$

$$\frac{(\bar{X} - \bar{Y}) - (u_1 - u_2)}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$\text{其中 } S_W^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}, S_W = \sqrt{S_W^2}$$

6.4 经验分布函数(数三)

大纲要求

了解 经验分布函数的概念和性质

经验分布函数

设 $x_1, x_2, \dots, x_n$ 是来自分布函数为 $F(x)$ 的总体 X 的样本观察值, X 的经验分布函数, 记为 $F_n(x)$, 定义为样本观察值 $x_1, x_2, \dots, x_n$ 中小于或等于指定值 x 所占的比率, 即

$$F_n(x) = \frac{\#(x_i \leq x)}{n}, \quad -\infty < x < \infty$$

其中 $\#(x_i \leq x)$ 表示 $x_1, x_2, \dots, x_n$ 中小于或等于 x 的个数。

$F_n(x)$ 是自变量 x 的函数，它具有分布函数的三个条件：

1, $F_n(x)$ 是 x 的不减函数

2, $0 \leq F_n(x) \leq 1$, $F_n(-\infty) = 0$, $F_n(\infty) = 1$

3, $F_n(x)$ 是右连续函数

因此可知 $F_n(x)$ 是一个分布函数。

一般的，设 $x_1, x_2, \dots, x_n$ 是总体 X 的一个容量为 n 的样本观察值，先将 $x_1, x_2, \dots, x_n$ 按自小到大的次序排序，并重新编号为

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

则经验分布函数 $F_n(x)$ 可写成

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ k/n, & x_{(k)} \leq x < x_{(k+1)} \\ 1, & x \geq x_{(n)} \end{cases}$$

其中 $k = 1, 2, \dots, n-1$

格里汶科定理

设 $X_1, X_2, \dots, X_n$ 是来自以 $F(x)$ 为分布函数的总体 X 的样本， $F_n(x)$ 是经验分布函数，则有

$$P \left\{ \lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0 \right\} = 1$$

这个定理说明了 $F_n(x)$ 在整个实轴上以概率 1 均匀收敛于 $F(x)$ 。当样本容量 n 足够大时， $F_n(x)$ 能够良好的逼近总体分布函数 $F(x)$ 。这也是以样本推断总体的依据。

七、参数估计

7.1 参数的点估计、估计量与估计值

大纲要求

理解参数的点估计、估计量与估计值的概念。

点估计、估计量与估计值的概念

设总体 X 的分布函数的形式已知，但它的的一个或多个参数未知，借助于总体 X 的一个样本来估计总体未知参数的值的问题，称为参数的点估计问题。

设总体 X 的分布函数 $F(X, \theta)$ 的形式为已知， θ 是待估参数。 $X_1, X_2, \dots, X_n$ 是 X 的一个样本， $x_1, x_2, \dots, x_n$ 是相应的一个样本值。点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ ，用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 作为未知参数 θ 的近似值。我们称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的**估计量**，称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的**估计值**。在不致混淆的情况下，统称估计量和估计值为**估计**。

7.2 矩估计法和最大似然估计法

大纲要求

掌握矩估计法(一阶矩、二阶矩)和最大似然估计法。

矩估计法

基于样本矩

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$$

依概率收敛于相应的总体矩 $u_l(l = 1, 2, \dots, k)$, 样本矩的连续函数依概率收敛于相应的总体矩的连续函数, 我们就用样本矩作为相应的总体矩的估计量, 而以样本矩的连续函数作为相应的总体矩的连续函数的估计量。这种估计方法称为矩估计法。

设 X 为连续型随机变量, 其概率密度为 $f(x; \theta_1, \theta_2, \dots, \theta_k)$, 或 X 为离散型随机变量, 其分布律为 $P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数, $X_1, X_2, \dots, X_n$ 是来自 X 的样本。假设总体 X 的前 k 阶矩

$$u_l = E(X^l) = \int_{-\infty}^{\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx \quad (X \text{ 为连续型})$$

或

$$u_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k) \quad (X \text{ 为离散型})$$

(其中 R_X 是 X 可能取值的范围)存在, $l = 1, 2, \dots, k$, 一般来说它们是 $\theta_1, \theta_2, \dots, \theta_k$ 的函数。

矩估计法的具体做法:

设

$$\begin{cases} u_1 = u_1(\theta_1, \theta_2, \dots, \theta_k), \\ u_2 = u_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \dots \dots \\ u_k = u_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$

这是包含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的联立方程组。可以从中解出 $\theta_1, \theta_2, \dots, \theta_k$, 得到

$$\begin{cases} \theta_1 = \theta_1(u_1, u_2, \dots, u_k), \\ \theta_2 = \theta_2(u_1, u_2, \dots, u_k) \\ \dots\dots\dots \\ \theta_k = \theta_k(u_1, u_2, \dots, u_k) \end{cases}$$

以 A_i 代替上式中的 u_i , $i = 1, 2, \dots, k$, 就以

$$\hat{\theta}_i = \theta_i(A_1, A_2, \dots, A_k), \quad i = 1, 2, \dots, k$$

分别作为 θ_i , $i = 1, 2, \dots, k$ 的估计量, 这种估计量称为**矩估计量**。矩估计量的观察值称为**矩估计值**。

最大似然估计法

若总体 X 属离散型, 其分布律 $P\{X = x\} = p(x; \theta)$, $\theta \in \Theta$ 的形式为已知, θ 为待估参数, Θ 是 θ 可能取值的范围。设 $X_1, X_2, \dots, X_n$ 是来自 X 的样本, 则 $X_1, X_2, \dots, X_n$ 的联合分布律为:

$$\prod_{i=1}^n p(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值。样本取得观察值的概率, 亦即事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \quad \theta \in \Theta$$

这一概率随 θ 的取值而变化, 它是 θ 的函数, 称为**样本的似然函数**。(注意这里的 $x_1, x_2, \dots, x_n$ 是已知的样本值, 它们都是常数)

由费希尔引进的最大似然估计法, 就是固定样本观察值 $x_1, x_2, \dots, x_n$, 在 θ 的可能取值范围 Θ 内挑选使似然函数 $L(x_1, x_2, \dots, x_n; \theta)$ 达到最大的参数值 $\hat{\theta}$, 作为参数 θ 的估计值。即取 $\hat{\theta}$ 使

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

这样得到的 $\hat{\theta}$ 与样本值 $x_1, x_2, \dots, x_n$ 有关, 常记为 $\hat{\theta}(x_1, x_2, \dots, x_n)$, 称为**参数 θ 的最大似然估计值**, 而相应的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为参数 θ 的**最大似然估计量**。

若总体 X 属连续型, 其概率密度 $f(x; \theta)$, $\theta \in \Theta$ 的形式为已知, θ 为待估参数, Θ 是 θ 可能取值的范围。设 $X_1, X_2, \dots, X_n$ 是来自 X 的样本, 则 $X_1, X_2, \dots, X_n$ 的联合概率密度为

$$\prod_{i=1}^n f(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值。则随机点 $(X_1, X_2, \dots, X_n)$ 落在点 $(x_1, x_2, \dots, x_n)$ 的邻域内的概率近似地为

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$

这里的因子 $\prod_{i=1}^n dx_i$ 不随 θ 而变化, 所以只需要考虑函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

的最大值。这里的 $L(\theta)$ 称为**样本的似然函数**。若

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的**最大似然估计值**, 称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的**最大似然估计量**。

这样, 确定最大似然估计量的问题就归结为微分学中求最大值的问题。

通常 $p(x_i; \theta)$ 和 $f(x_i; \theta)$ 关于 θ 可微, 这时 $\hat{\theta}$ 可从方程

$$\frac{d}{d\theta} L(\theta) = 0$$

解得。

因为 $L(\theta)$ 和 $\ln L(\theta)$ 在同一 θ 处取得极值，因此 $\hat{\theta}$ 也可从方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

求得，而求解这个方程往往比较方便。这个也称为**对数似然方程**。

最大似然估计法也适用于分布中含多个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的情况。这时，似然函数 L 是这些未知参数的函数，分别令

$$\frac{d}{d\theta_i} L = 0, \quad i = 1, 2, \dots, k$$

或令

$$\frac{d}{d\theta_i} \ln L = 0, \quad i = 1, 2, \dots, k$$

解上述由 k 个方程组成的方程组，即可得到各未知参数 θ_i ($i = 1, 2, \dots, k$)的最大似然估计值 $\hat{\theta}_i$ 。

最大似然估计具有下述性质

设 θ 的函数 $u = u(\theta)$, $\theta \in \Theta$ 具有单值反函数 $\theta = \theta(u)$ 。假设 $\hat{\theta}$ 是 X 的概率分布中参数 θ 的最大似然估计，则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计。

这一性质称为最大似然估计的**不变性**。

7.3 估计量的评选标准(数一)

大纲要求

了解估计量的无偏性、有效性(最小方差性)和一致性(相合性)的概念，

并会验证估计量的无偏性.

评选标准

无偏性

若估计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在, 且对于任意 $\theta \in \Theta$ 有

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的**无偏估计量**。

无偏估计的实际意义就是无系统误差。

样本均值 $\bar{X}$ 是总体均值 μ 的无偏估计; 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 σ^2 的无偏估计。而估计量 $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 却不是总体方差 σ^2 的无偏估计。因此我们一般取 S^2 作为 σ^2 的估计量。

有效性

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 与 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计量, 若对于任意 $\theta \in \Theta$, 有

$$D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$$

且至少对某一个 $\theta \in \Theta$ 上式中的不等号成立, 则 $\hat{\theta}_1$ 称 $\hat{\theta}_2$ 较**有效**。

这说明了无偏估计以方差小者为好。

相合性

设 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 θ 的估计量, 若对于任意 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}(X_1, X_2, \dots, X_n)$ 依概率收敛于 θ , 则称 $\hat{\theta}$ 为 θ 的**相合估计量**。

即对于任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$$

矩估计量是相合估计量。最大似然估计法得到的估计量，在一定条件下也具有相合性。

无偏性、有效性、相合性是评价估计量的基本标准。

7.4 区间估计(数一)

大纲要求

理解 区间估计的概念，

会求 单个正态总体的均值和方差的置信区间，

会求 两个正态总体的均值差和方差比的置信区间。

区间估计的概念

对于参数 θ ，除了求出它的点估计 $\hat{\theta}$ 外，我们还希望估计出一个范围，并希望知道这个范围包含参数 θ 真值的可信程度。这样的范围通常以区间的形式给出，同时还给出此区间包含参数 θ 真值的可信程度。这种形式的估计称为**区间估计**，这样的区间即所谓**置信区间**。

对于总体 X 的分布函数 $F(x; \theta)$ 含有一个未知参数 θ ， $\theta \in \Theta$ (Θ 是 θ 可能取值的范围)，对于给定值 α ($0 < \alpha < 1$)，若由来自 X 的样本 $X_1, X_2, \dots, X_n$ 确定的两个统计量 $\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$ 和 $\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$ ，($\underline{\theta} < \bar{\theta}$)，对于任意 $\theta \in \Theta$ 满足

$$P\{\underline{\theta}(X_1, X_2, \dots, X_n) < \theta < \bar{\theta}(X_1, X_2, \dots, X_n)\} \geq 1 - \alpha$$

则称随机区间 $(\underline{\theta}, \bar{\theta})$ 是 θ 的置信水平为 $1 - \alpha$ 的**置信区间**， $\underline{\theta}$ 和 $\bar{\theta}$ 分别称为置信水平

为 $1 - \alpha$ 的双侧置信区间的**置信下限**和**置信上限**， $1 - \alpha$ 称为**置信水平**。

寻求未知参数 θ 的置信区间的具体做法如下：

1，寻求一个样本 $X_1, X_2, \dots, X_n$ 和 θ 的函数 $W = W(X_1, X_2, \dots, X_n; \theta)$ ，使得 W 的分布不依赖于 θ 以及其他未知参数，称具有这种性质的函数为**枢轴量**。

2，对于给定的置信水平 $1 - \alpha$ ，定出两个常数 a, b ，使得

$$P\{a < W(X_1, X_2, \dots, X_n; \theta) < b\} = 1 - \alpha$$

若能从 $a < W(X_1, X_2, \dots, X_n; \theta) < b$ 得到与之等价的 θ 的不等式 $\underline{\theta} < \theta < \bar{\theta}$ ，其中 $\underline{\theta}(X_1, X_2, \dots, X_n)$ ， $\bar{\theta}(X_1, X_2, \dots, X_n)$ 都是统计量，那么 $(\underline{\theta}, \bar{\theta})$ 就是 θ 的一个置信水平为 $1 - \alpha$ 的置信区间。

单个正态总体

均值 μ 的置信区间

1， σ^2 为已知，此时

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

取 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ 为枢轴量， μ 的一个置信水平为 $1 - \alpha$ 的置信区间

$$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$$

2， σ^2 为未知，此时

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

取 $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ 作为枢轴量， μ 的一个置信水平为 $1 - \alpha$ 的置信区间

$$\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$$

方差 σ^2 的置信区间

σ^2 的无偏估计为 S^2 ，此时有

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

取 $\frac{(n-1)S^2}{\sigma^2}$ 作为枢轴量， σ^2 的一个置信水平为 $1-\alpha$ 的置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right)$$

两个正态总体

设已给定置信水平为 $1-\alpha$ ，并设 $X_1, X_2, \dots, X_{n_1}$ 是来自第一个总体的样本；

$Y_1, Y_2, \dots, Y_{n_2}$ 是来自第二个总体的样本，这两个样本相互独立。且设 $\bar{X}, \bar{Y}$ 分别为第

一、第二个总体的样本均值， S_1^2, S_2^2 分别是第一、第二个总体的样本方差。

两个总体均值差 $u_1 - u_2$ 的置信区间

1, σ_1^2, σ_2^2 均为已知， 此时

$$\frac{(\bar{X} - \bar{Y}) - (u_1 - u_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$

取 $\frac{(\bar{X} - \bar{Y}) - (u_1 - u_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$ 作为枢轴量，即得 $u_1 - u_2$ 的一个置信水平为 $1-\alpha$ 的置信区间

$$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$$

2, $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ，但 σ^2 为未知， 此时有

$$\frac{(\bar{X} - \bar{Y}) - (u_1 - u_2)}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中 $S_W^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$, $S_W = \sqrt{S_W^2}$

取 $\frac{(\bar{X} - \bar{Y}) - (u_1 - u_2)}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ 作为枢轴量，即得 $u_1 - u_2$ 的一个置信水平为 $1-\alpha$ 的置信区间

$$\left(\bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2)S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right)$$

两个总体方差比 σ_1^2/σ_2^2 的置信区间

均值 u_1, u_2 均为未知，此时有

$$\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

取 $\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2}$ 作为枢轴量，即得 σ_1^2/σ_2^2 的一个置信水平为 $1 - \alpha$ 的置信区间

$$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \quad \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right)$$

八、假设检验(数一)

8.1 假设检验的概念

大纲要求

理解显著性检验的基本思想,

掌握假设检验的基本步骤,

了解假设检验可能产生的两类错误。

显著性检验

在总体的分布函数完全未知或只知其形式,但不知其参数的情况下,为了推断总体的某些未知特性,提出某些关于总体的假设。我们根据样本对所提出的假设作出接受,还是拒绝的决策。**假设检验**就是作出这一决策的过程。

以均值的假设检验为例。

在显著性水平 α 下, 检验假设

$$H_0: u = u_0, H_1: u \neq u_0$$

也常说成, 在显著性水平 α 下, 针对 H_1 检验 H_0 。 H_0 称为**原假设**或**零假设**, H_1 称为**备选假设**。我们要做的是根据样本, 按照检验方法作出决策, 在 H_0 与 H_1 两者之间接受其一。

当检验统计量取某个区域 C 中的值时, 我们拒绝原假设 H_0 , 则称区域 C 为**拒绝域**, 拒绝域的边界点称为临界点。通常根据检验统计量与临界值的比较来作出决策。

上述假设中备选假设 H_1 ，表示： u 可能大于 u_0 ，也可能小于 u_0 ，这种形式称为**双边备择假设**，对应假设检验称为**双边假设检验**。

假设检验

$$H_0: u \leq u_0, H_1: u > u_0$$

称为**右边检验**。

假设检验

$$H_0: u \geq u_0, H_1: u < u_0$$

称为**左边检验**。右边检验和左边检验统称为**单边检验**。

假设检验可能产生的两类错误

由于检验法则是根据样本作出的，总有可能作出错误的决策。在假设 H_0 实际上为真时，我们可能犯拒绝 H_0 的错误，称这类弃真的错误为**第一类错误**。又当 H_0 实际上不真时，我们也有可能接受 H_0 ，称这类取伪的错误为**第二类错误**。

犯第二类错误的概率为：

$$P\{\text{当 } H_0 \text{ 不真时接受 } H_0\}$$

在样本容量固定时，减小犯一类错误的概率，则犯另一类错误的概率往往增大。在给定样本容量的情况下，一般来说，我们总是控制犯第一类错误的概率，使它不大于 α 。这种只对犯第一类错误的概率加以控制，而不考虑第二类错误的概率的检验，称为**显著性检验**。

假设检验的基本步骤

- 1，根据实际问题的要求，提出原假设 H_0 和备选假设 H_1
- 2，给定显著性水平 α 以及样本容量 n

- 3, 确定检验统计量以及拒绝域的形式
- 4, 按照 $P\{\text{当}H_0\text{为真时拒绝}H_0\} \leq \alpha$ 求出拒绝域
- 5, 取样, 根据样本观察值作出决策, 是接受 H_0 还是拒绝 H_0

8.2 正态总体的假设检验

大纲要求

掌握 单个及两个正态总体的均值和方差的假设检验

单个总体均值的检验

设总体 $X \sim N(u, \sigma^2)$, 检验问题

$$H_0: u = u_0, H_1: u \neq u_0$$

- 1, σ^2 为已知, 关于 u 的检验

检验统计量 $Z = \frac{\bar{X} - u_0}{\sigma/\sqrt{n}}$, 称为Z检验法

拒绝域 $\left| \frac{\bar{X} - u_0}{\sigma/\sqrt{n}} \right| \geq Z_{\alpha/2}$

- 2, σ^2 未知, 关于 u 的检验

检验统计量 $t = \frac{\bar{X} - u_0}{S/\sqrt{n}}$

拒绝域 $\left| \frac{\bar{X} - u_0}{S/\sqrt{n}} \right| \geq t_{\alpha/2}(n-1)$

两个总体均值的检验

检验问题 $H_0: u_1 - u_2 = \delta, H_1: u_1 - u_2 \neq \delta,$

$$\text{检验统计量: } t = \frac{(\bar{X} - \bar{Y}) - \delta}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

$$\text{其中 } S_W^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}, \quad S_W = \sqrt{S_W^2}$$

$$\text{拒绝域为 } |t| = \frac{|(\bar{X} - \bar{Y}) - \delta|}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \geq t_{\alpha/2}(n_1 + n_2 - 2)$$

单个总体方差的检验

$$\text{检验问题 } H_0: \sigma^2 = \sigma_0^2, \quad H_1: \sigma^2 \neq \sigma_0^2,$$

$$H_0 \text{ 为真时 } \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

$$\text{检验统计量 } \frac{(n-1)S^2}{\sigma_0^2}$$

$$\text{拒绝域 } \frac{(n-1)S^2}{\sigma_0^2} \leq \chi_{1-\alpha/2}^2(n-1) \text{ 或 } \frac{(n-1)S^2}{\sigma_0^2} \geq \chi_{\alpha/2}^2(n-1)$$

两个总体方差的检验

$$\text{检验问题 } H_0: \sigma_1^2 \leq \sigma_2^2, \quad H_1: \sigma_1^2 > \sigma_2^2,$$

$$\text{由前述知识可知 } \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$$

$$\text{检验统计量 } S_1^2/S_2^2$$

$$\text{拒绝域 } F = \frac{S_1^2}{S_2^2} \geq F_{\alpha}(n_1-1, n_2-1)$$

正态总体均值方差检验法(显著性水平为 α)

原假设 H_0	备选假设 H_1	检验统计量	拒绝域
$u \leq u_0$ $u \geq u_0$ $u = u_0$ $(\sigma^2 \text{已知})$	$u > u_0$ $u < u_0$ $u \neq u_0$	$Z = \frac{\bar{X} - u_0}{\sigma/\sqrt{n}}$	$z \geq z_\alpha$ $z \leq -z_\alpha$ $ z \geq z_{\alpha/2}$
$u \leq u_0$ $u \geq u_0$ $u = u_0$ $(\sigma^2 \text{未知})$	$u > u_0$ $u < u_0$ $u \neq u_0$	$t = \frac{\bar{X} - u_0}{S/\sqrt{n}}$	$t \geq t_\alpha(n-1)$ $t \leq -t_\alpha(n-1)$ $ t \geq t_{\alpha/2}(n-1)$
$u_1 - u_2 \leq \delta$ $u_1 - u_2 \geq \delta$ $u_1 - u_2 = \delta$ $(\sigma_1^2, \sigma_2^2 \text{已知})$	$u_1 - u_2 > \delta$ $u_1 - u_2 < \delta$ $u_1 - u_2 \neq \delta$	$Z = \frac{(\bar{X} - \bar{Y}) - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$z \geq z_\alpha$ $z \leq -z_\alpha$ $ z \geq z_{\alpha/2}$
$u_1 - u_2 \leq \delta$ $u_1 - u_2 \geq \delta$ $u_1 - u_2 = \delta$ $(\sigma_1^2 = \sigma_2^2 = \sigma^2 \text{未知})$	$u_1 - u_2 > \delta$ $u_1 - u_2 < \delta$ $u_1 - u_2 \neq \delta$	$t = \frac{(\bar{X} - \bar{Y}) - \delta}{S_W \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ $S_W^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$	$t \geq t_\alpha(n_1 + n_2 - 2)$ $t \leq -t_\alpha(n_1 + n_2 - 2)$ $ t \geq t_{\alpha/2}(n_1 + n_2 - 2)$
$\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$ $\sigma^2 = \sigma_0^2$ $(u \text{未知})$	$\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$ $\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2 \geq \chi_\alpha^2(n-1)$ $\chi^2 \leq \chi_\alpha^2(n-1)$ $\chi^2 \geq \chi_{\alpha/2}^2(n-1)$ 或 $\chi^2 \leq \chi_{1-\alpha/2}^2(n-1)$
$\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$ $\sigma_1^2 = \sigma_2^2$ $(u_1, u_2 \text{未知})$	$\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$ $\sigma_1^2 \neq \sigma_2^2$	$F = \frac{S_1^2}{S_2^2}$	$F \geq F_\alpha(n_1-1, n_2-1)$ $F \leq F_{1-\alpha}(n_1-1, n_2-1)$ $F \geq F_{\alpha/2}(n_1-1, n_2-1)$ 或 $F \leq F_{1-\alpha/2}(n_1-1, n_2-1)$

如有错误与建议，可向编者反馈。

